

WEBSIDIAN 합성 POC 증거 보고서

벤치마크 ID: `websidian-poc-retrieval-v1`

측정 실행시각: `2026-09-10T07:27:10.764Z`

심사위원용 60초 요약

- **무엇을 측정했나:** 합성 이슈 294건을 검색 공간으로 두고 대표 과제 3건의 관련 이력 순위를 비교했다.
- **무엇이 좋아졌나:** 모든 3등급 핵심 근거까지 필요한 평균 문서 순위가 `17.00건` → `6.67건`, Recall@10이 `85.71%` → `100.00%`가 됐다.
- **생산성의 의미는:** 실제 시간이 아니라 사람이 결과를 위에서부터 확인한다고 가정한 **문서 수 기반 대리지표**다.
- **AI 문맥은:** 완료 이력 후보 251건 중 과제별 7건을 선별했다. 251건 전체를 모델에 전송하지 않았고, 문자수 비율은 토큰·비용 절감률이 아니다.
- **분석·테스트의 역할은:** 선별된 원문을 읽기 쉬운 판단 초안과 과거 사이드·회귀 조건의 테스트 후보로 바꾸는 기능을 구현했다. 현재 벤치마크는 그 입력 근거의 회수 품질만 측정했으며 AI 출력 품질이나 장애 예방률은 측정하지 않았다.
- **숨기지 않은 실패는:** 엄격한 2-hop 경로 회수율 `83.33%`; 목표 노드는 찾았지만 더 강한 경유 경로 하나를 선택하지 못했다.
- **재현 위치:** `전체 결과`, `시나리오별 결과`, `숨기지 않은 실패 1건`, `재현 절차`와 동결 JSON-CSV를 함께 본다.

1. 결론과 주장 범위

완전 합성 이슈 294건을 사용한 대표 시나리오 3건에서 Websidian의 2-hop 탐색은 제목·본문 텍스트 기준선보다 관련 이력을 더 조밀하게 제시했다. 모든 3등급 핵심 근거까지 확인하는 데 필요한 문서 순위는 평균 `17.00건`에서 `6.67건`으로 낮아졌고, Top-10 유효근거 밀도는 `60.00%`에서 `100.00%`로 높아졌다. Recall@10은 `85.71%`에서 `100.00%`, nDCG@10은 `78.85%`에서 `90.53%`가 됐다.

이 결과가 증명하는 범위는 다음 세 가지다.

1. 동결된 합성 데이터와 정답셋에서의 검색 순위 품질
2. 사람이 결과를 순서대로 확인한다고 가정한 문서 수 기반 생산성 대리지표
3. 같은 프로세스·장비에서 측정한 서버 함수 실행시간과 AI 입력 후보 선별 규모

이 결과는 실제 키움증권 이슈, 고객정보, 회사 시스템 또는 현업 사용자의 업무를 측정하지 않았다. 실제 업무시간 단축, 생산성 향상, 비용 절감, 장애 감소, 장기 사용성 또는 인과관계 정확도로 해석해서는 안 된다.

2. 데이터와 과제

2.1 데이터 구성

구분	수량	역할
전체 합성 이슈	294건	검색·목록·그래프의 전체 공간
완료 이력 후보	251건	세 방법이 평가하는 과거 기록
진행 중 이슈	43건	기준 이슈와 배경 작업 노드
대표 이슈	24건	세 시나리오의 기준·관련 기록
일반 배경 이슈	270건	관련 없는 결과가 섞이는 실제적 탐색 난이도 구성

모든 ID, 제목, 본문, 날짜, 팀, 처리 결과와 `code:/`, `doc:/` 등의 자료 식별자는 POC용 가상 정보다. 실제 회사 기록을 익명화 해 옮긴 데이터도 아니다.

2.2 평가 과제

과제	기준 이슈	검증하는 문제	관련 완료 이력
과거 해결·로백 재사용	WS-008	중복 주문 증상에서 승인 상태, 요청 식별자와 과거 로백·회귀 조건을 찾는가	7건
기획 의도 보존	WS-016	이전 부서명 표시가 오류인지 완료 당시 정책인지 확인하는가	7건
타팀 변경의 파생 영향	WS-024	증상 표현이 다른 공통 날짜 유틸리티와 최근 타팀 변경까지 찾는가	7건

각 과제는 미해결 기준 이슈다. 관련 이력을 찾았다는 사실만으로 그것을 실제 원인이나 정답 처리라고 확정하지 않는다.

3. 프로토콜

3.1 비교 방법

방법	입력과 동작
baseline-text	기준 이슈의 제목과 본문만 기준 <code>searchIssues</code> 에 전달한다. 기준 이슈의 자료 식별자·처리 이력·태그는 사용하지 않는다.
websidian-search	제품의 <code>issueText</code> 와 <code>searchCompletedIssues</code> 를 그대로 사용해 원문과 자료를 함께 평면 순위화한다.
websidian-history	제품의 <code>buildHistory</code> 를 그대로 사용한다. 상위 직접 결과 최대 5건에서 완료 이력 이웃을 최대 2-hop으로 확장한다.

알고리즘을 평가 스크립트에 복사하지 않고 현재 제품 모듈을 직접 import했다. 세 방법 모두 진행 중 기준 이슈를 결과에서 제외하고 251개 완료 이력만 평가했다.

3.2 정답셋과 순환 검증 방지

`ground-truth.json`은 대표 이슈의 원문·자료·처리 기록을 읽어 작성한 평가 전용 qrels다. 제품 검색 순위에 주입하지 않는다.

- 3등급: 핵심 판단 또는 핵심 위험을 직접 뒷받침
- 2등급: 조사 범위·대안 원인·운영 경계를 유의미하게 보강
- 1등급: 핵심 답은 아니지만 배제 여부를 확인할 가치가 있음
- 0등급: 해당 시나리오 판단에 사용할 구체적 연결이 없음

각 시나리오에는 7개의 관련 이력, 기대 직접 이력과 기대 2-hop 경로가 별도로 고정돼 있다. 특히 WS-006의 허용 경로는 제품이 실제 선택한 경로가 아니라 원문상 더 강한 WS-005 → WS-006으로 사전에 기록됐다. 따라서 현재 출력에 맞춰 정답을 복사한 평가가 아니다.

권장 후속 검증은 두 명 이상의 검토자가 제품 순위를 보지 않고 qrels를 독립 판정하는 것이다. 현재 결과는 작은 자체 정답셋이라는 한계를 유지한다.

3.3 반복과 실행 환경

- 5회 준비 실행 후 과제×방법마다 100회 반복
- Node.js v24.15.0
- Windows 10.0.26200, x64
- CPU: 12th Gen Intel Core i7-12700H
- 실행시간: performance.now() 기반 서버 함수 시간
- 제외 범위: 파일 I/O, 네트워크, 브라우저 렌더링, 사용자의 읽기·판단 시간

4. 지표 정의

지표	정의	안전한 해석
Recall@10	Top-10에 포함된 관련 ID ÷ 관련 ID 7건	관련 이력을 결과 안에 회수한 비율
nDCG@10	관련성 등급과 순위를 함께 반영한 정규화 점수	핵심 기록을 앞쪽에 배치한 정도
Top-10 비관련 비율	반환된 Top-10 슬롯 중 관련 등급 0인 비율	결과 목록 안의 false-discovery 성격 지표
모든 3등급 근거까지 문서 순위	모든 핵심 이력이 나타난 경우 가장 뒤의 순위	순서대로 확인할 때 필요한 문서 수 proxy
유효근거 밀도@10	Top-10 슬롯 중 관련 등급 1~3 비율	결과 화면의 관련 정보 밀도
3등급 Coverage@10	Top-10에 포함된 3등급 ID ÷ 전체 3등급 ID	핵심 근거 누락 여부
직접 경로 회수율	기대 직접 ID를 depth 1로 회수한 비율	직접 조사 후보 재현
2-hop 목표 회수율	기대 원거리 target을 depth 2로 회수한 비율	떨어진 기록의 발견 여부
엄격 2-hop 경로 회수율	target과 허용 경유 ID가 모두 맞은 비율	설명 경로까지 맞았는지 분리 평가

Recall@5는 각 과제의 관련 이력이 7건이므로 이론적 최대가 5/7, 즉 71.43%다. 세 방법 모두 이 최대값에 도달했다. MRR도 세 방법 모두 1.0이다. 따라서 첫 관련 결과 하나를 찾는 능력만으로 Websidian의 우위를 주장하지 않는다.

5. 전체 결과

지표	텍스트 기준선	Websidian 검색	Websidian 2-hop
Recall@10	85.71%	90.48%	100.00%
nDCG@10	78.85%	84.54%	90.53%
Top-10 비관련 결과 비율	40.00%	36.67%	0.00%
모든 3등급 근거까지 필요한 문서 순위	17.00건	14.00건	6.67건

지표	텍스트 기준선	Websidian 검색	Websidian 2-hop
Top-10 유효근거 밀도	60.00%	63.33%	100.00%
3등급 핵심근거 Coverage@10	80.56%	88.89%	100.00%
직접 경로 회수율	해당 없음	해당 없음	100.00%
2-hop 목표 회수율	해당 없음	해당 없음	100.00%
엄격 2-hop 경로 회수율	해당 없음	해당 없음	83.33%

기준선 대비 2-hop의 차이는 Recall@10 **+14.29%p**, nDCG@10 **+11.68%p**, 유효근거 밀도 **+40.00%p** 다. 모든 핵심 근거까지 필요한 평균 순위는 **10.33건**, 비율로는 **60.78%** 감소했다.

이 감소율은 문서 **순위 수**의 변화다. 한 문서의 길이, 읽기 난이도, 사람이 판단한 시간과 실제 이슈 처리시간을 측정하지 않았으므로 **업무시간 60.78% 절감** 이라고 표현하지 않는다.

6. 시나리오별 결과

과제	비교	Recall@10	nDCG@10	모든 3등급까지	유효밀도@10	엄격 경로
WS-008 롤백	기준선	71.43%	78.30%	14건	50.00%	해당 없음
WS-008 롤백	2-hop	100.00%	96.02%	7건	100.00%	50.00%
WS-016 기획 의도	기준선	100.00%	97.79%	5건	70.00%	해당 없음
WS-016 기획 의도	2-hop	100.00%	98.55%	6건	100.00%	100.00%
WS-024 타팀 영향	기준선	85.71%	60.45%	32건	60.00%	해당 없음
WS-024 타팀 영향	2-hop	100.00%	77.03%	7건	100.00%	100.00%

세부 결과는 평균만으로 가려지는 차이를 보여준다.

- WS-008** 은 핵심 이력 누락과 잡음이 줄었지만 엄격한 경유 경로 하나가 틀렸다.
- WS-016** 은 텍스트 기준선이 이미 강했다. 2-hop은 Top-10 잡음을 없앴지만 모든 핵심 근거까지의 순위는 **5 → 6건** 으로 한 건 나빠졌다. 그래프가 모든 과제의 모든 지표를 개선한다고 주장하지 않는다.
- WS-024** 는 증상과 표현이 다른 타팀 변경을 찾는 시나리오에서 가장 큰 차이가 나타났다. 모든 핵심 근거까지 필요한 순위가 **32 → 7건** 으로 줄었다.

7. 생산성 대리지표의 의미

첫 3등급 근거까지 필요한 문서 수는 세 방법 모두 평균 **1.33건** 이었다. 즉 Websidian이 첫 번째 그럴듯한 기록을 더 빨리 보여줬다는 증거는 없다. 관측된 이점은 여러 이슈에 흩어진 핵심 근거를 Top-10 안에 빠짐없이 모으고 비관련 결과를 줄이는 단계에 있다.

발표에서 사용할 수 있는 문장은 다음 범위다.

합성 시나리오 3건에서 Websidian 2-hop은 모든 핵심 근거가 나타나는 평균 순위를 17.00건에서 6.67건으로 낮췄습니다.

다음 문장은 현재 증거로 사용할 수 없다.

- 이슈 처리시간을 60.78% 단축했다.
- 실제 운영자의 조사시간을 10.33건만큼 줄였다.
- 장애나 사이드 이슈를 100% 예방한다.
- 키움증권 또는 계열사 전체의 생산성을 향상했다.

이를 검증하려면 실제 참여자가 기존 방식과 Websidian을 교차 순서로 사용하고, 첫 유효근거 발견시간·처리방향 확정시간·핵심근거 발견률·테스트 조건 누락을 별도로 측정해야 한다.

7.1 테스트 케이스의 실무 가치 가설과 다음 측정

현재 구현은 연결된 완료 이력에서 정상 흐름뿐 아니라 과거 재시도, 롤백, 날짜·상태 경계, 타팀 변경과 회귀 조건을 테스트 초안으로 제안한다. 개발자가 자신이 구현한 정상 경로를 가장 잘 아는 반면, 변경이 닿는 다른 화면·공통 모듈·과거 장애 조건은 놓치기 쉽다는 문제를 보완하려는 기능이다.

다만 이번 자체 벤치마크는 검색 근거의 순위와 밀도를 평가했을 뿐, 생성된 테스트의 결함 검출력은 평가하지 않았다. 제한 파일럿에서는 정답이 있는 사이드 결함 과제를 두고 **핵심 조건 회수율**, **기존 수동 케이스 대비 추가 유효 조건 수**, **중복·오탐 비율**, **검토·수정 시간**, **배포 후 회귀 결함**을 분리 측정해야 한다. 따라서 현재 안전한 주장은 **과거 사이드 이력을 테스트 후보로 전환하는 워크플로를 구현했다** 까지다.

8. AI 문맥 효율 대리 측정

제품의 **buildIssueInsightContext**가 각 기준 이슈에서 실제로 선택한 문맥과, 동일한 필드·발췌 길이로 완료 이력 251건 전체를 투영한 비교 문맥을 직렬화해 비교했다. 비교 문맥은 모델에 전송하지 않았고 비용도 발생시키지 않았다.

기준 이슈	선택 이력	전체 완료 이력	선택 문맥	전체 비교 문맥	문자수 비율
WS-008	7건	251건	6,468자	173,650자	3.72%
WS-016	7건	251건	6,102자	173,649자	3.51%
WS-024	7건	251건	6,146자	173,669자	3.54%
평균	7건	251건	범위 6,102~6,468자	범위 173,649~173,669자	3.59%

건수 기준으로는 **7/251**, 즉 **2.79%**의 완료 이력만 선택됐다. 평균 문자수 비율은 3.59%로 전체 비교 문맥보다 96.41% 작았다. 전체 비교 문맥은 세 과제 모두 현재 64KB 입력 제한을 초과했다.

문자수는 토큰이 아니고, 문자수 비율은 비용 비율이 아니다. 시스템 프롬프트와 모델별 토큰나이저, 추론 토큰, 캐시, 제공자 가격이 포함되지 않았기 때문이다. 따라서 현재 안전한 결론은 **관련 완료 이력 후보와 직렬화 문맥을 제한했다** 까지다.

9. AI 텔레메트리

9.1 구현된 측정 항목

분석, 테스트 케이스, 파생 기억, 문서 임베딩과 쿼리 임베딩 호출에는 다음 메타데이터를 기록할 수 있다.

- 요청·제공 모델 ID와 프롬프트 버전
- 추론 강도, 근거 수와 입력 문자수
- 시작·완료시각, 첫 출력 시간(TTFT)과 총시간
- 입력·출력·추론·캐시·전체 토큰

- OpenRouter가 반환한 경우의 비용
- 제공자 요청 ID, 시도 횟수, 종료 사유
- 성공·부분·폴백·취소·오류 상태와 오류 단계

측정 테이블에는 프롬프트, 이슈 원문, 생성 결과, API 키와 이메일을 저장하지 않는다. 인증 소유자 값은 일방향 SHA-256 범 위값으로 저장하며, 현재 사용자의 행만 `/api/metrics/llm?format=csv` 로 내보낼 수 있다.

9.2 현재 증거 상태

이번 검색 벤치마크는 유료 LLM 생성이나 임베딩 호출을 수행하지 않았다. 따라서 이 보고서에는 실제 모델 ID, TTFT, 총 생성 시간, 토큰, 제공자 비용, 재시도율 또는 폴백률의 관측값이 없다. 텔레메트리 구현과 AI 자원 실측 결과를 같은 것으로 취급하지 않는다.

OpenRouter 비용은 응답에 값이 있을 때만 `openrouter-credit` 의 백만분을 정수로 저장한다. 임베딩 응답이 비용을 주지 않으면 빈 값을 0원으로 해석하거나 전체 AI 비용으로 합산해서는 안 된다. 제출 전에 실제 호출을 근거로 사용할 경우 OpenRouter 사용 내역과 CSV를 대조해야 한다.

10. 서버 함수 실행시간

방법	p50	p95
텍스트 기준선	13.0347ms	14.4240ms
Websidian 검색	16.0464ms	17.8971ms
Websidian 2-hop	38.5890ms	42.9335ms

2-hop은 기준선보다 로컬 서버 함수 시간이 길었다. 품질 개선과 함께 이 계산비용을 숨기지 않는다. 다만 이 수치는 데이터 로딩, 네트워크, 브라우저, AI 생성과 사람이 읽는 시간을 제외하므로 실제 화면 응답시간으로 사용할 수 없다. 다른 장비와의 절대 비교에도 적합하지 않다.

11. 숨기지 않은 실패 1건

`WS-008` 의 기대 2-hop 경로 두 개 중 `WS-002` 는 허용된 `WS-007 → WS-002` 경로로 찾았다. `WS-006` 도 depth 2에서 회수했지만, 사전에 고정한 더 강한 `WS-005 → WS-006` 이 아니라 `WS-007 → WS-006` 으로 제시했다.

- 2-hop 목표 회수: 성공
- 엄격한 경로 회수: 실패
- WS-008 엄격 경로 회수율: `1/2`, 50.00%
- 전체 엄격 경로 회수율: `5/6`, 83.33%

이 실패는 목표 노드를 찾는 것과 설명 가능한 경유 경로를 고르는 것이 다른 문제임을 보여준다. 정답셋을 결과에 맞춰 수정하지 않았다. 후속 개선 후보는 공유 자료의 종류와 처리 이력 근거를 경로 선택 점수에서 분리하고, 동일 target의 복수 경로를 사용자에게 보여주는 것이다. 개선 후에는 같은 고정 qrels로 재측정해야 한다.

12. 한계

1. 대표 시나리오가 3건으로 작고 제품의 핵심 사용 사례를 의도적으로 구성했다.
2. 294건 모두 합성 데이터이며 실제 조직의 용어 분포·오류·권한·노이즈를 재현한다고 보증하지 않는다.

3. 정답셋은 자체 작성됐으며 아직 복수 독립 평가자의 합의도를 측정하지 않았다.
4. 사용자 참여 실험이 없어 실제 탐색시간, 처리 품질, 학습효과, 만족도와 지속 사용을 모른다.
5. AI 생성 품질·인용 사실성·토큰·비용·장애통을 이번 실행에서 측정하지 않았다.
6. 함수 시간은 POC 규모와 한 장비의 상대 수치다.
7. 관계선·유사도·시간 근접성과 hop은 조사 후보이며 원인 확률 또는 인과 증명이 아니다.
8. 실행 환경과 순간 부하는 함수 시간에 영향을 준다. 절대시간이나 사용자 체감시간이 아니라 동일 실행 안의 상대 결과로만 해석한다.

13. 재현 절차

프로젝트 루트에서 실행한다.

```
node --experimental-strip-types scripts/eval-retrieval.mjs `
  --iterations 100 `
  --output-dir evidence/poc-benchmark/results
```

입력 파일:

- `data/issues.json`
- `evidence/poc-benchmark/task-set.json`
- `evidence/poc-benchmark/ground-truth.json`

출력 파일:

- `evidence/poc-benchmark/results/retrieval-eval.json`
- `evidence/poc-benchmark/results/retrieval-eval.csv`

동결 식별자:

항목	값
데이터 SHA-256	<code>133a63f0926f8c7d025e9e00305b11f37a402a98aefc4084403c2be9bc540805</code>
과제셋 SHA-256	<code>ed225179fed57e01c9c2afe595bc1e7ec64ec702589157231a41d6123ba5a0a0</code>
정답셋 SHA-256	<code>ff04bec85818a4634b8dc9b49585a316f7c33e5172d187bfbdb11e8f2786cbdc</code>
기록된 Git commit	<code>6d67aa93a5dbf1dc2b5f1cbc7b63cfe2614895f4</code>
작업 트리 상태	<code>trackedWorkingTreeDirty: false</code>

평가 코드·입력·정답셋을 위 commit으로 먼저 고정한 뒤 같은 명령을 실행했다. 결과 파일은 이 실행의 commit·입력 해시·실행시각과 함께 동결하며, 후속 측정값이 달라지면 기존 결과를 덮어 감추지 않고 버전을 분리한다.

14. 제출용 한 문장

완전 합성 이슈 294건·대표 과제 3건에서 WEBSIDIAN 2-hop은 핵심 근거 전체가 나타나는 평균 순위를 17.00건에서 6.67건으로 낮췄습니다. 이는 실제 업무시간 절감이 아닌 검색 순위 기반 POC 관측값입니다.